

Рубежный контроль №1 по курсу "Методы машинного обучения в АСОИУ"

Мамоу Асман, группа ИУ5-21М

Вариант №9

1. Цель работы

- Провести первичную обработку реального набора данных, содержащего числовые и категориальные переменные:
- Освоить метод заполнения пропусков «хвостом распределения» на примере признака `bmi`.
- Научиться выявлять и удалять константные и псевдоконстантные признаки.
- Построить и проанализировать диаграмму рассеяния для двух числовых переменных.

2. Используемые библиотеки и загрузка данных

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

df = pd.read_csv('healthcare-dataset-stroke-data.csv')
print("Размер данных:", df.shape)
df.head()
```

Размер данных: (5110, 12)

	id	gender	age	hypertension	heart_disease	ever_married	work_type
0	9046	Male	67.0	0	1	Yes	Private
1	51676	Female	61.0	0	0	Yes	Self-employed
2	31112	Male	80.0	0	1	Yes	Private
3	60182	Female	49.0	0	0	Yes	Private

Далее: [New interactive sheet](#)

3. Обзор структуры и пропусков датасета

```
print(df.info())
print("\nКоличество пропусков по столбцам:")
print(df.isnull().sum())
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5110 entries, 0 to 5109
Data columns (total 12 columns):
 #   Column                Non-Null Count  Dtype
---  -
 0   id                    5110 non-null   int64
 1   gender                5110 non-null   object
 2   age                   5110 non-null   float64
 3   hypertension          5110 non-null   int64
 4   heart_disease         5110 non-null   int64
 5   ever_married          5110 non-null   object
 6   work_type              5110 non-null   object
 7   Residence_type        5110 non-null   object
 8   avg_glucose_level     5110 non-null   float64
 9   bmi                   4909 non-null   float64
10   smoking_status        5110 non-null   object
11   stroke                 5110 non-null   int64
dtypes: float64(3), int64(4), object(5)
memory usage: 479.2+ KB
None
```

Количество пропусков по столбцам:

id	0
gender	0
age	0
hypertension	0
heart_disease	0
ever_married	0
work_type	0
Residence_type	0
avg_glucose_level	0
bmi	201
smoking_status	0
stroke	0

dtype: int64

- Всего 12 столбцов, 5110 записей.
- Единственный признак с пропусками – **bmi** (201 пропуск).
- Остальные столбцы полные, типы данных корректны.

4. Устранение пропусков признака **bmi** методом «хвост распределения»

Суть метода:

Вместо заполнения средним или медианой мы заменяем пропуски значением, лежащим в хвосте распределения (например, $\text{mean} + 3 \cdot \text{std}$). Это позволяет выделить наблюдения с пропусками как аномальные, что может быть полезно при дальнейшем моделировании.

```
bmi_mean = df['bmi'].mean()
bmi_std = df['bmi'].std()

tail_value = bmi_mean + 3 * bmi_std
print(f"Среднее BMI: {bmi_mean:.2f}, Стандартное отклонение: {bmi_std:.2f}")
print(f"Заполняем пропуски значением: {tail_value:.2f}")

df['bmi_tail_imputed'] = df['bmi'].fillna(tail_value)

print("\nПропусков в новом столбце:", df['bmi_tail_imputed'].isnull().sum())
print("Описательная статистика до/после:")
print(pd.DataFrame({
    'исходный bmi': df['bmi'].describe(),
    'bmi (хвост)': df['bmi_tail_imputed'].describe()
})))
```

Среднее BMI: 28.89, Стандартное отклонение: 7.85
Заполняем пропуски значением: 52.46

Пропусков в новом столбце: 0
Описательная статистика до/после:

	исходный bmi	bmi (хвост)
count	4909.000000	5110.000000
mean	28.893237	29.820048
std	7.854067	8.957807
min	10.300000	10.300000
25%	23.500000	23.800000
50%	28.100000	28.400000
75%	33.100000	34.000000
max	97.600000	97.600000

Пропуски в `bmi` (201 шт.) заполнены значением $\approx \text{mean} + 3\sigma$. Теперь в столбце `bmi_tail_imputed` пропусков нет, а аномально высокое значение искусственно помечает факт отсутствия данных.

5. Удаление константных и псевдоконстантных признаков

Критерии:

- **Константный признак** – только одно уникальное значение.

- **Псевдоконстантный признак** – одно значение встречается более чем в 95% случаев (порог можно настраивать).

```
threshold = 0.95

const_cols = []
pseudo_const_cols = []

for col in df.columns:
    if col == 'id':
        continue
    top_freq = df[col].value_counts(normalize=True).max()
    nunique = df[col].nunique()

    if nunique == 1:
        const_cols.append(col)
    elif top_freq >= threshold:
        pseudo_const_cols.append(col)

print("Константные признаки:", const_cols if const_cols else "отсутствуют")
print("Псевдоконстантные (порог {}): {}".format(threshold, pseudo_const_cols))

df_clean = df.drop(columns=const_cols + pseudo_const_cols)
print("\nИсходное количество столбцов:", df.shape[1])
print("После удаления констант/псевдоконстант:", df_clean.shape[1])
```

```
Константные признаки: отсутствуют
Псевдоконстантные (порог 0.95): ['stroke']
```

```
Исходное количество столбцов: 13
После удаления констант/псевдоконстант: 12
```

В наборе данных константные признаки не найдены, однако обнаружен псевдоконстантный признак `stroke` (доля доминирующего класса превысила порог 95%). Это объясняется сильным дисбалансом целевой переменной: большинство наблюдений относятся к классу «0» (нет инсульта). После удаления `stroke` из набора данных исходное количество столбцов сократилось с 13 до 12. Таким образом, выполнена очистка от малоинформативного признака.

✓ 6. Доп. задание: диаграмма рассеяния для пары колонок


Выбранные признаки: `age` и `avg_glucose_level`

Построим scatter plot, чтобы визуальнo оценить взаимосвязь возраста и среднего уровня глюкозы.

```
# Настройка стиля
sns.set_style("whitegrid")
```

```
plt.figure(figsize=(8,6))

# Диаграмма рассеяния
sns.scatterplot(data=df, x='age', y='avg_glucose_level',
                hue='stroke', alpha=0.6, palette={0:'blue', 1:'red'})
plt.title('Диаграмма рассеяния: возраст vs средний уровень глюкозы')
plt.xlabel('Возраст')
plt.ylabel('Средний уровень глюкозы')
plt.legend(title='Инсульт (0/1)')
plt.show()
```



- Цветом выделен статус инсульта (красный – был инсульт).
- Заметно, что с возрастом увеличивается разброс уровня глюкозы, и среди пожилых пациентов чаще встречаются случаи инсульта при высоком уровне глюкозы.

7. Выводы

- Выполнена загрузка и первичный анализ набора данных.

- **Заполнение хвостом распределения** для `bmi` успешно выполнено: все пропуски замещены экстремально высоким значением `mean+3σ`, что сохраняет информацию о самом факте пропуска.
- **Поиск константных и псевдоконстантных признаков** показал, что в данных нет столбцов, подлежащих удалению по этим критериям. Все признаки вариативны.
- **Диаграмма рассеяния** наглядно продемонстрировала распределение уровня глюкозы по возрастам и выделила группу риска инсульта.
- Все этапы обработки проиллюстрированы кодом на Python, работа готова к сдаче.